Инвестиции в компании-стартапы

В нашем распоряжении база данных, которая хранит информацию о венчурных фондах и инвестициях в компании-стартапы. Эта база данных основана на датасете Startup Investments, опубликованном на популярной платформе для соревнований по исследованию данных Kaggle.

Цель проекта: проанализировать данные о фондах и инвестициях и с помощью различных SQL-запросов к базе данных. Продемонстрировать изученные операторы, функции и методы работы с базой данных.

Описание проекта:

Познакомимся с важными понятиями, которые встретятся в работе с базой данных:

Венчурные фонды — это финансовые организации, которые могут позволить себе высокий риск и инвестировать в компании с инновационной бизнес-идеей или разработанной новой технологией, то есть в старталы. Цель венчурных фондов — в будущем получить значительную прибыль, которая в разы превысит размер их трат на инвестиции в компанию. Если стартап подорожает, венчурный фонд может получить долю в компании или фиксированный процент от её выручки.

Чтобы процесс финансирования стал менее рискованным, его делят на стадии — *раунды*. Тот или иной раунд зависит от того, какого уровня развития достигла компания.

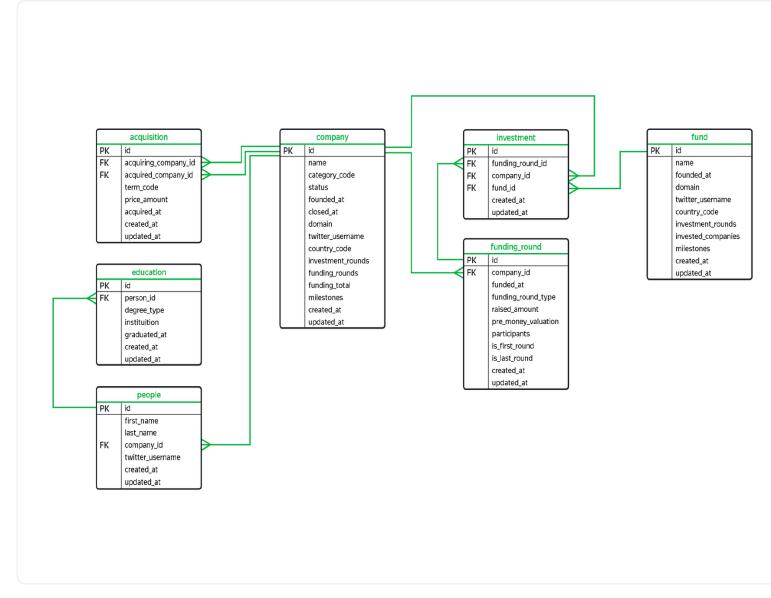
Первые этапы — *предпосевной* и *посевной* раунды. Предпосевной раунд предполагает, что компания как таковая ещё не создана и находится в стадии замысла. Следующий — посевной — раунд знаменует рост проекта: создатели компании разрабатывают бизнесмодель и привлекают инвесторов.

Если компании требуется ментор или наставник — она привлекает *бизнес-ангела*. Бизнесангелы — инвесторы, которые помимо финансовой поддержки предлагают экспертную помощь. Такой раунд называют *ангельским*.

Когда стартап становится компанией с проверенной бизнес-моделью и начинает зарабатывать самостоятельно, предложений инвесторов становится больше. Это раунд A, а за ним следуют и другие: B, C, D — на этих этапах компания активно развивается и готовится к IPO.

Иногда выделяют *венчурный раунд* — финансирование, которое могло поступить от венчурного фонда на любом этапе: начальном или более позднем.

ER-диаграмма базы данных



Ознакомимся с данными, которые хранят таблицы:

Acquisition

Содержит информацию о покупках одних компаний другими:

- первичный ключ id идентификатор или уникальный номер покупки;
- внешний ключ acquiring_company_id ссылается на таблицу company идентификатор компании-покупателя, то есть той, что покупает другую компанию;
- внешний ключ acquired_company_id ссылается на таблицу company идентификатор компании, которую покупают;
- term_code способ оплаты сделки:
 - o cash наличными;
 - о stock акциями компании;
 - o cash_and_stock смешанный тип оплаты: наличные и акции.
- price_amount сумма покупки в долларах;
- acquired_at дата совершения сделки;
- created_at дата и время создания записи в таблице;
- updated_at дата и время обновления записи в таблице.

Company

Содержит информацию о компаниях-стартапах:

- первичный ключ id идентификатор, или уникальный номер компании;
- пате название компании;
- category_code категория деятельности компании, например:
 - о news специализируется на работе с новостями;
 - o social специализируется на социальной работе.
- status статус компании:
 - o acquired приобретена;
 - o operating действует;
 - іро вышла на ІРО;
 - о closed перестала существовать.
- founded_at дата основания компании;
- closed_at дата закрытия компании, которую указывают в том случае, если компании больше не существует;
- domain домен сайта компании;
- twitter_username название профиля компании в твиттере;
- country_code код страны, например, USA для США, GBR для Великобритании;
- investment_rounds число раундов, в которых компания участвовала как инвестор;
- funding_rounds число раундов, в которых компания привлекала инвестиции;
- funding_total сумма привлечённых инвестиций в долларах;
- milestones количество важных этапов в истории компании;
- created_at дата и время создания записи в таблице;
- updated_at дата и время обновления записи в таблице.

Education

Хранит информацию об уровне образования сотрудников компаний:

- первичный ключ id уникальный номер записи с информацией об образовании;
- внешний ключ person_id ссылается на таблицу people идентификатор человека, информация о котором представлена в записи;
- degree type учебная степень, например:
 - о ва Bachelor of Arts бакалавр гуманитарных наук;
 - о мs Master of Science магистр естественных наук.
- instituition учебное заведение, название университета;
- graduated_at дата завершения обучения, выпуска;
- created_at дата и время создания записи в таблице;
- updated_at дата и время обновления записи в таблице.

Fund

Хранит информацию о венчурных фондах:

- первичный ключ id уникальный номер венчурного фонда;
- пате название венчурного фонда;
- founded_at дата основания фонда;
- domain домен сайта фонда;
- twitter_username профиль фонда в твиттере;
- country_code код страны фонда;

- investment_rounds число инвестиционных раундов, в которых фонд принимал участие;
- invested_companies число компаний, в которые инвестировал фонд;
- milestones количество важных этапов в истории фонда;
- created_at дата и время создания записи в таблице;
- updated_at дата и время обновления записи в таблице.

Funding_round

Содержит информацию о раундах инвестиций:

- первичный ключ id уникальный номер инвестиционного раунда;
- внешний ключ company_id ссылается на таблицу company уникальный номер компании, участвовавшей в инвестиционном раунде;
- funded_at дата проведения раунда;
- funding_round_type ТИП ИНВЕСТИЦИОННОГО раунда, например:
 - o venture венчурный раунд;
 - о angel ангельский раунд;
 - o series_a раунд А.
- raised_amount сумма инвестиций, которую привлекла компания в этом раунде в долларах;
- pre_money_valuation предварительная, проведённая до инвестиций оценка стоимости компании в долларах;
- participants количество участников инвестиционного раунда;
- is_first_round является ли этот раунд первым для компании;
- is_last_round является ли этот раунд последним для компании;
- created at дата и время создания записи в таблице;
- updated_at дата и время обновления записи в таблице.

Investment

Содержит информацию об инвестициях венчурных фондов в компании-стартапы:

- первичный ключ id уникальный номер инвестиции;
- внешний ключ funding_round_id ссылается на таблицу funding_round уникальный номер раунда инвестиции;
- внешний ключ company_id ссылается на таблицу company уникальный номер компании-стартапа, в которую инвестируют;
- внешний ключ fund_id ссылается на таблицу fund уникальный номер фонда, инвестирующего в компанию-стартап;
- created_at дата и время создания записи в таблице;
- updated_at дата и время обновления записи в таблице.

People

Содержит информацию о сотрудниках компаний-стартапов:

- первичный ключ id уникальный номер сотрудника;
- first_name имя сотрудника;
- last_name фамилия сотрудника;
- внешний ключ company_id ссылается на таблицу company уникальный номер компании-стартапа;
- twitter_username профиль сотрудника в твиттере;

- created_at дата и время создания записи в таблице;
- updated_at дата и время обновления записи в таблице.

Исследуем рынок венчурных фондов и инвестиций в компании-стартапы с помощью запросов к базе данных:

1. Посчитаем, сколько компаний закрылось:

SELECT COUNT(id)
FROM company

WHERE status = 'closed'

Результат

count	
2584	

2. Отобразим количество привлечённых средств для новостных компаний США. Отсортируем таблицу по убыванию суммы привлечённых инвестиций в долларах. Ограничим таблицу 5 строками:

SELECT SUM(funding_total)
FROM company
WHERE category_code = 'news' AND
country_code = 'USA'
GROUP BY id
ORDER BY SUM(funding_total) DESC
LIMIT 5

sum		
6.22553e+08		
2.5e+08		
1.605e+08		
1.28e+08		
1.265e+08		

3. Найдем общую сумму сделок по покупке одних компаний другими в долларах. Отберем сделки, которые осуществлялись только за наличные с 2011 по 2013 год включительно:

SELECT SUM(price_amount)

FROM acquisition

WHERE term_code = 'cash' AND

EXTRACT(YEAR FROM acquired_at) BETWEEN 2011 AND 2013

Результат

sum
1.37762e+11

4.Отобразим имя, фамилию и названия аккаунтов людей в твиттере, у которых названия аккаунтов начинаются на 'Silver':

SELECT first_name,

last_name,

twitter_username

FROM people

WHERE twitter_username LIKE 'Silver%'

Результат

first_name	last_name	twitter_username
Rebecca	Silver	SilverRebecca
Silver	Teede	SilverMatrixx
Mattias	Guilotte	Silverreven

5. Выведем на экран всю информацию о людях, у которых названия аккаунтов в твиттере содержат подстроку 'money', а фамилия начинается на 'K':

SELECT *

FROM people

WHERE twitter_username LIKE '%money%' AND

last_name LIKE 'K%'

id	first_name	last_name	company_id	twitter_username	created_at	updated_at
63081	Gregory	Kim		gmoney75	2010-07-13 03:46:28	2011-12-12 22:01:34

6. Для каждой страны отобразим общую сумму привлечённых инвестиций, которые получили компании, зарегистрированные в этой стране. Ограничим таблицу 15 странами:

```
SELECT country_code,
SUM(funding_total)
FROM company
GROUP BY country_code
ORDER BY SUM(funding_total) DESC
LIMIT 15
```

Результат

country_code	sum
USA	3.10588e+11
GBR	1.77056e+10
CHN	1.06897e+10
CAN	9.86636e+09
IND	6.14141e+09
DEU	5.76577e+09
FRA	4.59514e+09
ISR	4.48009e+09
СНЕ	2.82925e+09
NLD	2.35397e+09

7. Составим таблицу, в которую войдёт дата проведения раунда, а также минимальное и максимальное значения суммы инвестиций, привлечённых в эту дату. Оставим в итоговой таблице только те записи, в которых минимальное значение суммы инвестиций не равно нулю и не равно максимальному значению. Ограничим таблицу 10 строками:

```
SELECT funded_at,

MIN(raised_amount),

MAX(raised_amount)

FROM funding_round

GROUP BY funded_at

HAVING MIN(raised_amount) <> 0 AND

MIN(raised_amount) <> MAX(raised_amount)

LIMIT 10
```

Результат

funded_at	min	max
2012-08-22	40000	7.5e+07
2010-07-25	3.27825e+06	9e+06
2002-03-01	2.84418e+06	8.95915e+06
2010-10-11	28000	2e+08
2007-01-18	5.5e+06	2.3e+07
2007-02-27	1.29e+06	3.6e+07
2006-01-05	8.9e+06	2.65e+07
2011-10-31	35000	2.5e+07
2012-10-27	500000	9.3e+06
2007-08-16	2.51989e+06	9e+06

8. Создадим поле с категориями:

- Для фондов, инвестирующих в 100 и более компаний, назначим категорию high_activity;
- Для фондов, инвестирующих в 20 и более компаний до 100 middle_activity;
- Если количество инвестируемых компаний фонда не достигает 20 low_activity.

Отобразим все поля таблицы fund и новое поле с категориями:

```
SELECT *, CASE
```

```
WHEN invested_companies > 100 THEN 'high_activity'
WHEN invested_companies BETWEEN 20 AND 100 THEN 'middle_activity'
WHEN invested_companies < 20 THEN 'low_activity'
END AS activity
```

FROM fund

activity	id	name	found ed_at	domain	country _code	investment _rounds	invested_ companies	mi les to ne s
high_ activity	1	Greylock Partners	1965- 01-01	greylock. com	USA	307	196	0
middle_ activity	10	Mission Ventures	1996- 01-01	missionve ntures. com	USA	58	33	0
low_ activity	100	Kapor Enterpris es		kei.com	USA	2	1	0
low_ activity	1000	Speed Ventures				0	0	1
low_ activity	10001	Salem Partners	1997- 01-01	salempart ners.com	USA	1	1	0
low_ activity	10002	3T Capital		3tcapital.	FRA	3	3	0
low_ activity	10003	Merieux Develop pement	2009- 01-01	merieux- developpe ment.com	FRA	2	2	0
low_ activity	10004	Aquasou rca		aquasourc a.com	FRA	1	1	0

9. Посчитаем для каждой из категорий округлённое до ближайшего целого числа среднее количество инвестиционных раундов, в которых фонд принимал участие. Выведем на экран категории и среднее число инвестиционных раундов. Отсортируем таблицу по возрастанию среднего:

SELECT CASE

```
WHEN invested_companies>=100 THEN 'high_activity'
WHEN invested_companies>=20 THEN 'middle_activity'
ELSE 'low_activity'
END AS activity,
ROUND(AVG(investment_rounds)) AS avg_investment_rounds
```

FROM fund

GROUP BY activity

ORDER BY avg_investment_rounds

Результат

activity	avg_investment_rounds
low_activity	2
middle_activity	51
high_activity	252

10. Проанализируем, в каких странах находятся фонды, которые чаще всего инвестируют в стартапы. Для каждой страны посчитаем минимальное, максимальное и среднее число компаний, в которые инвестировали фонды этой страны, основанные с 2010 по 2012 год включительно. Исключим страны с фондами, у которых минимальное число компаний, получивших инвестиции, равно нулю.

Выгрузим десять самых активных стран-инвесторов: отсортируем таблицу по среднему количеству компаний от большего к меньшему. Затем добавим сортировку по коду страны в лексикографическом порядке. Ограничим таблицу 10 странами:

```
SELECT country_code,
        MIN(invested_companies),
        MAX(invested_companies),
        AVG(invested_companies)
FROM fund
WHERE EXTRACT(YEAR FROM founded_at) BETWEEN 2010 AND 2012
GROUP BY country_code
HAVING MIN(invested_companies) <> 0
ORDER BY AVG(invested_companies) DESC, country_code
LIMIT 10
```

country_code	min	max	avg
BGR	25	35	30
CHL	29	29	29

country_code	min	max	avg
UKR	8	10	9
LTU	5	5	5
IRL	4	5	4.5
KEN	3	3	3
LBN	3	3	3
MUS	3	3	3
JPN	1	6	2.83333
HKG	2	3	2.66667

11. Отобразим имя и фамилию всех сотрудников стартапов. Добавим поле с названием учебного заведения, которое окончил сотрудник, если эта информация известна. Ограничим таблицу 5 строками:

```
SELECT p.first_name,
p.last_name,
e.instituition
```

FROM people p

LEFT JOIN education e ON p.id = e.person_id

LIMIT 5

first_name	last_name	instituition		
John	hn Green Washington University, St.			
John	Green	Boston University		
David	Peters	Rice University		
Dan	Birdwhistell	University of Cambridge		
Gal	Cohen	Tel Aviv University		

12. Для каждой компании найдём количество учебных заведений, которые окончили её сотрудники. Выведем название компании и число уникальных названий учебных заведений. Составим топ-5 компаний по количеству университетов:

SELECT c.name,

COUNT(DISTINCT e.instituition)

FROM company c

LEFT JOIN people p ON c.id = p.company_id

INNER JOIN education e ON p.id = e.person_id

GROUP BY c.name

ORDER BY COUNT(DISTINCT e.instituition) DESC

LIMIT 10

name	count
Google	167
Yahoo!	115
Microsoft	111
Knight Foundation	74
Comcast	66
McKinsey & Company	52
Amazon	52
TechCrunch	43
MySpace	42
eBay	42

13. Составим список с уникальными названиями закрытых компаний, для которых первый раунд финансирования оказался последним:

1 вариант:

```
SELECT DISTINCT name
FROM company
WHERE id IN (SELECT company_id
             FROM funding_round fr
             INNER JOIN company c ON fr.company_id = c.id
             WHERE fr.is_first_round = 1 AND
                   fr.is_last_round = 1 AND
                   status = 'closed')
```

2 вариант:

```
SELECT DISTINCT name
FROM company c
INNER JOIN funding_round fr ON fr.company_id = c.id
WHERE fr.is_first_round = 1 AND
      fr.is_last_round = 1 AND
     status = 'closed'
```

Результат		
name		
10BestThings		
11i Solutions		
169 ST.		
1bib		
1Cast		
1DayMakeover		
25eight		
27 Perry		
2Win-Solutions		
3Touch		

14. Составим список уникальных номеров сотрудников, которые работают в компаниях, отобранных в предыдущем задании. Ограничим таблицу 5 строками:

Результат

id	
62	
97	
98	
225	
226	

15. Составим таблицу, куда войдут уникальные пары с номерами сотрудников из предыдущей задачи и учебным заведением, которое окончил сотрудник. Ограничим таблицу 5 строками:

id	instituition		
349	AKI		
349	ArtEZ Hogeschool voor de Kunsten		
349	Rijks Akademie		
699	Imperial College		
779	Harvard University		

16. Посчитаем количество учебных заведений для каждого сотрудника из предыдущего задания. Ограничим таблицу 5 строками:

SELECT a.id,
COUNT(a.instituition)
FROM a
GROUP BY a.id
LIMIT 5

Результат

Тезультат		
id	count	
8666	2	
9397	2	
6087	1	
9643	2	
73469	1	

17. Дополним предыдущий запрос и выведем среднее число учебных заведений (всех, не только уникальных), которые окончили сотрудники разных компаний:

SELECT AVG(a.number_of_instituitions) AS avg_number_of_instituitions
FROM a

Результат

avg_number_of_instituitions

1.41509

18. Выведем среднее число учебных заведений (всех, не только уникальных), которые окончили сотрудники Facebook:

SELECT AVG(a.number_of_instituitions) AS avg_facebook
FROM a

Результат

avg_facebook
1.51111

19. Составим таблицу из полей:

- name_of_fund название фонда;
- name of company название компании;
- amount сумма инвестиций, которую привлекла компания в раунде.

В таблицу войдут данные о компаниях, в истории которых было больше шести важных этапов, а раунды финансирования проходили с 2012 по 2013 год включительно. Ограничим таблицу 5 строками:

LIMIT 5

name_of_fund	name_of_company	amount
SAP Ventures	OpenX	2.50112e+07
Samsung Ventures	OpenX	2.50112e+07
Index Ventures	OpenX	2.50112e+07
Presidio Ventures	OpenX	2.50112e+07
DAG Ventures	Gigya	2.5e+07

20. Выгрузим таблицу, в которой будут такие поля:

- название компании-покупателя;
- сумма сделки;
- название компании, которую купили;
- сумма инвестиций, вложенных в купленную компанию;
- доля, которая отображает, во сколько раз сумма покупки превысила сумму вложенных в компанию инвестиций, округлённая до ближайшего целого числа.

При этом не будем учитывать те сделки, в которых сумма покупки равна нулю. Если сумма инвестиций в компанию равна нулю, также исключим такую компанию из таблицы.

Отсортируем таблицу по сумме сделки от большей к меньшей, а затем по названию купленной компании в лексикографическом порядке. Ограничим таблицу 10 строками:

acquiring_company	price_amount	acquired_company	funding_total	share
Microsoft	8.5e+09	Skype	7.6805e+07	111
Scout Labs	4.9e+09	Varian Semiconductor Equipment Associates	4.8e+06	1021
Broadcom	3.7e+09	Aeluros	7.97e+06	464
Broadcom	3.7e+09	NetLogic Microsystems	1.88527e+08	20
Level 3 Communications	3e+09	Global Crossing	4.1e+07	73
Yahoo!	2.87e+09	GeoCities	4e+07	72
eBay	2.6e+09	Skype	7.6805e+07	34
Salesforce	2.5e+09	ExactTarget	2.3821e+08	10
Johnson & Johnson	2.3e+09	Crucell	4.43e+08	5
IAC	1.85e+09	Ask.com	2.5e+07	74

21. Выгрузим таблицу, в которую войдут названия компаний из категории social, получившие финансирование с 2010 по 2013 год включительно. Сумма инвестиций не должна быть равна нулю. Выведем также номер месяца, в котором проходил раунд финансирования. Ограничим таблицу 5 строками:

company_name	month
Klout	1
WorkSimple	3
HengZhi	1
Twitter	1
SocialGO	1

- 22. Отберём данные по месяцам с 2010 по 2013 год, когда проходили инвестиционные раунды. В итоговой таблице должны быть следующие поля:
 - номер месяца, в котором проходили раунды;
 - количество уникальных названий фондов из США, которые инвестировали в этом месяце;
 - количество компаний, купленных за этот месяц;
 - общая сумма сделок по покупкам в этом месяце.

```
WITH a AS (SELECT EXTRACT(MONTH FROM fr.funded at) AS month,
           COUNT(DISTINCT f.name) AS fund_amount
           FROM funding_round fr
           LEFT JOIN investment i ON i.funding round id = fr.id
           LEFT JOIN fund f ON i.fund id = f.id
           WHERE country_code = 'USA' AND
           EXTRACT(YEAR FROM fr.funded_at) BETWEEN 2010 AND 2013
           GROUP BY month),
     b AS (SELECT EXTRACT(MONTH FROM acquired at) AS month,
           COUNT(acquired_company_id) AS company_amount,
           SUM(price_amount) AS total_price
           FROM acquisition a
           WHERE EXTRACT(YEAR FROM acquired_at) BETWEEN 2010 AND 2013
           GROUP BY month)
SELECT a.month,
       a.fund_amount,
       b.company amount,
       b.total price
FROM a
LEFT JOIN b ON a.month = b.month
```

Результат

month	fund_amount	company_amount	total_price
1	815	600	2.71083e+10
2	637	418	4.13903e+10
3	695	458	5.95016e+10
4	718	411	3.03837e+10
5	695	532	8.60122e+10
6	785	525	5.20883e+10
7	803	488	4.98541e+10
8	726	454	7.77093e+10
9	793	491	6.97409e+10
10	764	473	4.85567e+10
11	661	414	4.79386e+10
12	590	433	3.74251e+10

23. Составим сводную таблицу и выведем среднюю сумму инвестиций для стран, в которых есть стартапы, зарегистрированные в 2011, 2012 и 2013 годах. Отсортируем таблицу по среднему значению инвестиций за 2011 год от большего к меньшему. Ограничим таблицу 15 странами:

SELECT a.country_code, a.avg_2011, b.avg_2012, c.avg_2013

FROM a

INNER JOIN b ON a.country_code = b.country_code
INNER JOIN c ON a.country_code = c.country_code
ORDER BY a.avg_2011 DESC
LIMIT 15

country_code	avg_2011	avg_2012	avg_2013
PER	4e+06	41000	25000
USA	2.24396e+06	1.20671e+06	1.09336e+06
HKG	2.18078e+06	226227	0
PHL	1.75e+06	4218.75	2500
ARE	1.718e+06	197222	35333.3
JPN	1.66431e+06	674720	50000
AUT	1.5342e+06	147806	85773.3
BRA	1.38007e+06	240639	67944.4
DEU	1.1288e+06	1.32915e+06	66612.7
ISR	1.03076e+06	1.27121e+06	294022
PST	1e+06	0	0
FRA	977874	291227	642083
CHN	975918	611436	1e+06
AUS	963088	192949	26313.7
ZAF	962000	576000	0